




Algoritmo de detección de recuperación autónoma post carga cognitiva mediante análisis de HRV en estudiantes universitarios

Introducción a Señales Biomédicas



UNIVERSIDAD PERUANA CAYETANO HEREDIA

Introducción

- La **carga cognitiva** representa el esfuerzo mental requerido durante tareas complejas. Este esfuerzo se refleja objetivamente en la HRV que funciona como **indicador directo del sistema nervioso autónomo** y adaptabilidad al estrés. Cuando el estrés aumenta, la HRV disminuye, y cuando el cuerpo se recupera, debería volver a subir. [1]–[3].



Problemática

Limitaciones actuales

- Evaluación de carga cognitiva basada principalmente en métodos subjetivos [4], [5].
- Estudios de HRV se enfocan mayormente en la respuesta durante la tarea cognitiva [4], [6].

Vacío científico

- Poca investigación sobre recuperación autonómica post carga cognitiva mediante HRV [4], [6].
- Escasos estudios en estudiantes universitarios relacionados con recuperación fisiológica y estrés académico [6], [8].
- Falta de algoritmos simples para detectar recuperación autonómica usando ECG y HRV.

Consecuencias

- Dificultad para detectar fatiga mental y sobrecarga cognitiva temprana [5], [8].
- Posible impacto en rendimiento académico y estrés estudiantil [6], [8].

Objetivo general

Desarrollar un algoritmo de detección de recuperación autonómica post carga cognitiva mediante análisis de HRV en estudiantes universitarios, utilizando señales ECG obtenidas durante fases de reposo, esfuerzo cognitivo y recuperación fisiológica.

Objetivos específicos

1. Registrar señales ECG durante reposo, carga cognitiva y recuperación.
2. Extraer métricas HRV mediante análisis de RMSSD.
3. Analizar la recuperación autonómica posterior al esfuerzo cognitivo.
4. Diseñar un algoritmo para detectar patrones de recuperación post carga cognitiva.
5. Evaluar la relación entre HRV y estrés académico en estudiantes universitarios.



FASE 1: Diseño del estudio

Tipo de Estudio

Diseño: Transversal, experimental

Sesión Unica: 3 fases secuenciales con registro ECG continuo

Control: Cada participante actúa como su propio control [9]

Muestra

Edad: 18–30 años, con ritmo sinusal normal

Captación: Por convocatoria interna en la universidad

Criterio de inclusión

Estudiante universitario activo (18–30 años)

Ritmo cardíaco sinusal normal

Sin medicación que altere FC

Criterio de Exclusión

Arritmias cardíacas diagnosticadas o marcapasos

Uso de psicofármacos o fármacos cronotrópicos

Trastorno de ansiedad o depresión activos

Reposo Basal

10 min

Participante sentado,
sin actividad



Recuperación

20 min


Reposo pasivo, ECG
continuo




Carga Cognitiva

15 min

Tarea N-back 2-back
ms) [10]





Adquisición de señal ECG

- Hombro derecho

+ Hombro izquierdo

T cresta iliaca

Equipos: BITalino, electrodos desechables, OpenSignals

Cuestionarios: PSS-10 — Al inicio · Mide estrés académico basal (covariable) [11]

NASA-TLX — Post-tarea · Valida que la tarea fue percibida como demandante

FASE 2: Arquitectura del Algoritmo

1

1. Filtrado de Señal

Preprocesamiento de la señal ECG para eliminar ruido eléctrico, extraer métricas HRV y preparar los datos. Son los cimientos limpios para el análisis de la IA.

2

2. 1D-CNN

Una CNN unidimensional extrae patrones locales y comprime la secuencia temporal a la mitad, eliminando micro-ruidos fisiológicos y acelerando el procesamiento. [9]

3

3. TCN Causal

La Red Convolutiva Temporal (TCN) analiza el contexto a largo plazo con un enfoque causal, entendiendo la tendencia de recuperación solo mirando el pasado. [10]

4

4. Dot Attention

Esta capa de Atención Temporal (Dot-Product) evalúa la memoria reciente, dando mayor peso al instante exacto de la primera señal clara de relajación. [11]

FASE 3: Métricas a recolectar y plan de análisis

1. Métricas fisiológicas y calidad de la señal

Tipo	Métrica	Función en el algoritmo
ECG procesado	Señal ECG filtrada	Base para detectar picos R y obtener intervalos R-R
Intervalos R-R	Tiempo entre latidos consecutivos	Entrada principal para el cálculo de HRV
RMSSD por ventanas	HRV en segmentos temporales	Permite observar caída y recuperación autonómica
RMSSD basal	Valor de referencia en reposo	Define la línea base individual
RMSSD mínimo	Menor valor durante carga/post-carga	Representa el mayor impacto de la tarea cognitiva
% señal válida	Calidad del ECG útil	Determina si el registro puede analizarse

FASE 3: Métricas a recolectar y plan de análisis

2. Salidas del algoritmo

Salida	Definición	Interpretación
Índice de Recuperación Autonómica / IRC	Porcentaje de retorno del RMSSD hacia el valor basal	Cuantifica qué tanto se recuperó el sistema autonómico
Tiempo de recuperación	Minuto en que RMSSD se aproxima al basal	Evalúa la rapidez de recuperación
Curva RMSSD vs tiempo	Evolución de HRV por ventanas	Permite visualizar caída y retorno autonómico
Clasificación final	Rápida, parcial, lenta o no evaluable	Resume la respuesta fisiológica individual

FASE 3: Métricas a recolectar y plan de análisis

3. Validación exploratoria y análisis

Métrica externa	Momento	Uso en el análisis
NASA-TLX	Después del 2-back	Confirmar que la tarea fue percibida como demandante [12]
Accuracy del 2-back	Durante la tarea	Verificar desempeño y compromiso del participante [13]
Tiempo de reacción	Durante la tarea	Complementar la evaluación de carga cognitiva
PSS-10	Antes del protocolo	Comparar recuperación autonómica con estrés percibido basal [14]

Bibliografía

- [1] Malik, M., "Heart rate variability: standards of measurement..." IEEE Trans. Biomed. Eng., 1996.
- [2] Shaffer, F.; Ginsberg, J.P., "An overview of heart rate variability metrics and norms", Front. Public Health, 2017.
- [3] Kim, H.-G.; Cheon, E.-J.; Bai, D.-S.; et al., "Stress and heart rate variability: a meta-analysis", Neurosci. Biobehav. Rev., 2018.
- [4] J. Wei et al., "Cognitive Load Inference Using Physiological Markers in Virtual Reality," in 2025 IEEE Conference on Virtual Reality and 3D User Interfaces (VR), 2025.
- [5] A. Bhatti et al., "CLARE: Cognitive Load Assessment in Realtime with Multimodal Data," arXiv:2404.17098, 2024.
- [6] Z. Ahmad et al., "Multi-level Stress Assessment from ECG in a Virtual Reality Environment using Multimodal Fusion," arXiv:2107.04566, 2021.
- [7] A. Henelius, "A Short Review and Primer on Cardiovascular Signals in Human-Computer Interaction Applications," arXiv:1612.07677, 2016.
- [8] M. Pradeep et al., "Cross-Modal Computational Model of Brain-Heart Interactions via HRV and EEG Features," arXiv:2601.06792, 2026.
- [9] Londoño-Vargas, A. et al. (2025). Longitudinal effects of stress in an academic context on HRV and wellbeing in university students. *PMC12239435*.
- [10] Laborie, G. et al. (2019). Mental workload alters heart rate variability, lowering non-linear dynamics. *Frontiers in Physiology*. PMC6528181.
- [11] Analog Devices (2020). AD8232 Single-Lead, Heart Rate Monitor Front End — *Data Sheet Rev. D*. Analog Devices Inc.
- [12] J. Deng, J. Yang, X. Wang, and X. Zhang, "A Novel Instruction Driven 1-D CNN Processor for ECG Classification," Sensors, 2024.
- [13] Y. Zhao, J. Ren, B. Zhang, J. Wu, and Y. Lyu, "An explainable attention-based TCN heartbeats classification model for arrhythmia detection," Biomedical Signal Processing and Control, 2022, doi: 10.1016/j.bspc.2022.104337.
- [14] M. I. Ahmad, I. Keller, D. A. Robb, and K. S. Lohan, "A framework to estimate cognitive load using physiological data," Personal and Ubiquitous Computing, vol. 27, pp. 2027–2041, Sep. 2023.
- [15] N. Chambon et al., "Detection of cognitive load modulation by EDA and HRV," *Front. Physiol.*, 2025.
- [16] J. Radun et al., "The effects of irrelevant speech on physiological stress, cognitive performance, and subjective experience – focus on heart rate variability," *Int. J. Psychophysiol.*, vol. 200, 2024.
- [17] P. Králíčková et al., "Heart rate variability, perceived stress and willingness to seek counselling in undergraduate students," J. Psychosom. Res., 2022.